

Discurso de ódio e Inteligência Artificial

Novembro 2023 | Veridiana

Ethical and technical challenges of AI in tackling hate speech

Diogo Cortiz & Arkaitz Zubiaga

- 1.) Repensar a **conceituação de “violência”** na era digital.
- 2.) Os autores propõe a ideia de “online harms” como “any illegal or unacceptable activity that can put a person, a group of people, and even democratic institutions at risk, often leading to consequences for the offline world”
- 3.) **Online harms** é mais amplo do que isso - > uma série de efeitos prejudiciais que os usuários podem experimentar como resultado de suas interações online ou do consumo de conteúdo on-line, incluindo “impactos psicológicos” ligados à dependência de plataformas digitais ou efeitos negativos na saúde mental devido a conteúdos ou comportamentos online.
- 4.) A violência online é um subconjunto de “online harms”, mas com uma intenção e implicação claras de causar danos psicológicos, emocionais ou físicos.

Ethical and technical challenges of AI in tackling hate speech

Diogo Cortiz & Arkaitz Zubiaga

4.) Os “online harms” podem ou não atingir o limiar do que é **legal/ilegal** ou geralmente reconhecido como violência. Alguns exemplos:

4a.) **Cyberstalking**: Atenção persistente e ameaçadora através de canais online que podem criar uma sensação de medo e angústia (“Crime de perseguição” previsto pela lei Lei 14.132/21)

4b.) **Assédio online**: desde “trollagem” persistente até campanhas de assédio direcionadas (“Crime de doxxing” Art. 154-a do Código Penal)

4c.) **Ameaças de violência física**: Comunicar ameaças à segurança física de alguém através de meios digitais.

4d.) **Pornografia de vingança ou pornografia não consensual**: Compartilhamento de imagens ou vídeos íntimos de alguém sem o seu consentimento (Artigo 218-C do Código Penal)

4e.) **Incitação à violência**: Utilização de plataformas online para encorajar a violência física contra indivíduos ou grupos.

Ethical and technical challenges of AI in tackling hate speech

Diogo Cortiz & Arkaitz Zubiaga

5.) O problema da regulação:

5a.) UK propôs um “regulatory framework”

Brasil discute o “PL 2630/2020”

5b.) O que mudou dos debates envolvidos na LGPD e esses novos debates regulatórios?

LGPD

Transmissão de informações com fontes detectáveis

Dados digitais coletados por empresas e entidades governamentais

Se aplica a qualquer operação de tratamento de dados pessoais, seja por entidades privadas ou públicas, online ou offline

Estabelece a necessidade de consentimento para coleta e tratamento de dados, direitos dos titulares de dados, e penalidades para casos de não conformidade

PL Fake News

Transmissão de informações com fontes não detectáveis

Dados/informações/conteúdos disseminadas nas redes sociais

Se aplica principalmente a plataformas digitais e serviços de comunicação na internet, como redes sociais e aplicativos de mensagens

Propõe a criação de normas para a atuação de plataformas de redes sociais e serviços de mensagens, com penalidades para o não cumprimento.

Ethical and technical challenges of AI in tackling hate speech

Diogo Cortiz & Arkaitz Zubiaga

7.) **Definição de discurso de ódio**

7a.) Algumas plataformas possuem uma definição de Hate Speech:

"a direct attack on people based on what we call protected characteristics - race, ethnicity, national origin, religious affiliation, sexual orientation, caste, sex, gender, gender identity and serious disease or disability. We protect against attacks on the basis of age when age is paired with another protected characteristic, and also provide certain protections for immigration status. We define attack as violent or dehumanising speech, harmful stereotypes, statements of inferiority or calls for exclusion or segregation" (Facebook, 2020)

"Hateful conduct: You may not promote violence against or directly attack or threaten other people on the basis of race, ethnicity, national origin, caste, sexual orientation, gender, gender identity, religious affiliation, age, disability, or serious disease. We also do not allow accounts whose primary purpose is inciting harm towards others on the basis of these categories" (Twitter, 2020)

"Hate speech is not allowed on YouTube. We remove content promoting violence or hatred against individuals or groups based on any of the following attributes: Age, Caste, Disability, Ethnicity, Gender, Identity and Expression, Nationality, Race Immigration, Status, Religion, Sex/Gender, Sexual Orientation, Victims of a major violent event and their kin Veteran Status" (Youtube, 2020)

Ethical and technical challenges of AI in tackling hate speech

Diogo Cortiz & Arkaitz Zubiaga

8.) **NLP: Bert e Roberta**

8a.) Buscaram desenvolver um modelo próprio de linguagem a partir de um conjunto de dados extraídos da API do Twitter

8b.) Fazem um etiquetamento (rótulo) de alguns exemplos de hate speech (exige um trabalho interdisciplinar)

8c.) Desenvolvimento de modelo de linguagem

8d.) Fine tuning: retreinamento do modelo em cima dos exemplos rotulados

9) Problemas que foram identificados a partir desse modelo:

9a.) Falta de representatividade nos dados

9b.) Anonymization

9c.) Atribuição de sentido no momento da rotulação: eles tinha pelo menos 3 anotadores e estabeleceram um “valor de concordância”. É um desagio estabelecer o que se entende por “hate speech”

10.) AI como ferramenta que apoia a decisão humana e não que substitui: “In our project, we advocate that the automated hate speech detection process is just a tool to help the moderation team deal with the large volume of content posted daily. The system would only be responsible for placing a "mark" on the content so that it could be analyzed by a human moderator. In this case, the lack of a plausible explanation by the AI is less sensitive, because the final decision on whether or not to remove content is up to the moderator.”

Combining artificial intelligence and expert content analysis to explore radical views on twitter: Case study on far-right discourse

Imene Ajala, Shanaz Feroze, May El Barachi, Farhad Oroumchian, Sujith Mathew, Rand Yasin, Saad Lutfi

1.) Eles partem de um fenômeno que anterior ao discurso de ódio, o “processo de radicalização”:

1a.) Objetivo: *“in identifying ‘extreme’ views that can potentially lead to radical behaviors and actions. Indeed, extreme and radical views expressed publicly are often considered as precursors to violent actions such as riots, civil disobedience, and in extreme cases terrorist attacks”.*

1b.) O que eles entendem por “radicalização”: “Radicalization represents the process by which individuals are influenced to develop extreme views, attitudes, and behaviors”

2.) Objetivo do artigo: “a sustainable and sophisticated technological solution for the analysis of extreme views expressed on social media”.

Combining artificial intelligence and expert content analysis to explore radical views on twitter: Case study on far-right discourse

Imene Ajala, Shanaz Feroze, May El Barachi, Farhad Oroumchian, Sujith Mathew, Rand Yasin, Saad Lutfi

3.) Como analisar o process de radicalização e não apenas o discurso de ódio?

Considerando que as social media são uma ferramenta chave para formação da radicalização e propagação dos discursos de ódio

3a.) A rede social (social network) é mais importante para analisar o processo de radicalização do que apenas o discurso.

3b.) O texto apresenta uma série de trabalhos que usam classificadores baseados em técnicas relacionados à IA (machine learning, data mining, natural language processing) mas alega que todos caem em classificações dualistas: discursos extremistas x discursos não extremistas.

3c.) Os autores afirmam que o objetivo de estudos que buscam identificar discursos de ódio devem levar em considerações o processo de radicalização que desemboca em discursos de ódio e para isso vários aspectos devem ser levados em consideração: aderência a certas ideologias, interações sociais, pressão/influência dos pares. Além disso, a dimensão temporal é importante.

Combining artificial intelligence and expert content analysis to explore radical views on twitter: Case study on far-right discourse

Imene Ajala, Shanaz Feroze, May El Barachi, Farhad Oroumchian, Sujith Mathew, Rand Yasin, Saad Lutfi

4.) O passo a passo metodológico:

4a.) Identificação do tipo de extremismo/ideologia expressos -> a raspagem já possui um viés inicial pois eles coletam apenas tweets relacionados a hashtags extremistas: #chinesevirus #whitelivesmatter #buildthewall. Depois, optaram por uma técnica de clusterização (aprendizagem de máquina não supervisionada) sem ter que rotular.

4b.) Nível de radicalização do discurso -> IBM Watson Natural Language Understanding service para análise de sentimento (positivos e negativos).

4c.) The level of users' engagement -> análise de curtidas, número de seguidores e compartilhamento

4d.) Identificação de opiniões de líderes e usuários influentes -> "link analysis" (network analysis) é muito importante não apenas para criar categorizações ou análises mas também previsões. Uso de medidas de centralidade, betweenness (pessoas que funcionam como pontes).